

回归分析

续本达

复习提示

线性回归

多元线性回归

模型选择

热敏电阻

泊松回归

广义线性回归

# 回归分析

续本达

清华大学 工程物理系

2025-07-16 清华

- `lm-examples.tar.gz` 线性回归样例集

```
wget http://hep.tsinghua.edu.cn/~orv/pd/lm-examples.tar.gz  
tar -xf lm-examples.tar.gz
```

## 安装 rhdf5

```
# Debian  
apt install r-bioc-rhdf5
```

- DataFrame（数据表格）与 SQL 一样，是关系代数的具体实现
  - DataFrame 更动态，可联用更多丰富的语言功能
- GNU R 语言是统计学领域的编程语言
  - 提供了跨领域的与统计学高效的对话方式

## ggplot2

- 把数据表格的列映射到图中的要素
  - 例如 x 轴、y 轴、颜色等


```
ggplot(mtcars, aes(x=wt, y=hp)) + geom_point()
```

## dplyr 与 dbplyr

- 关系代数的基本操作对应到命令

```
students |> inner_join(longscores) |>
```

```
group_by(班级, 作业) |> summarise(平均分=mean(分数))
```



- 以关系代数的数据形式为核心
  - 实现列的对称性
- 工具设计和使用变得简单
  - 一行代码绘图
  - 一行代码回归
  - 类比：一行命令实现一个功能
  - 一次原则：只输入必要信息
  - 保证数据的透明：更易于理解
- 人更能专注于高层次的概念与问题，不被细节湮没

## 推论：数据分析最佳工具策略

- 原始数据尽快等价变换成关系代数形式：站在统计学与图形巨人的肩膀上



- 复习：线性回归，最小二乘法

| $Y$ | $x$ |
|-----|-----|
| 2   | 1   |
| 5.5 | 3   |
| 6.5 | 4   |
| 9   | 7   |

- $y = a + bx + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma^2)$
- $Y = y - \epsilon$ ,  $Y$  和  $\epsilon$  是随机变量
- $(Y, x)$  是关系，组成表格
- 表格 DataFrame 之上自然进行回归分析

## 读入例子：书的重量

```
books = read.csv("lm-examples/books.csv",  
                 row.names=1)
```

books

|    | volume | area | weight | cover |
|----|--------|------|--------|-------|
| 1  | 885    | 382  | 800    | hb    |
| 2  | 1016   | 468  | 950    | hb    |
| 3  | 1125   | 387  | 1050   | hb    |
| 4  | 239    | 371  | 350    | hb    |
| 5  | 701    | 371  | 750    | hb    |
| 6  | 641    | 367  | 600    | hb    |
| 7  | 1228   | 396  | 1075   | hb    |
| 8  | 412    | 0    | 250    | pb    |
| 9  | 953    | 0    | 700    | pb    |
| 10 | 929    | 0    | 650    | pb    |
| 11 | 1492   | 0    | 975    | pb    |
| 12 | 419    | 0    | 350    | pb    |
| 13 | 1010   | 0    | 950    | pb    |
| 14 | 595    | 0    | 425    | pb    |
| 15 | 1034   | 0    | 725    | pb    |

- hb 代表 hard back ， 硬质纸壳封面封底
- pb 代表 paper back ， 软纸封面封底
- area 代表封面的面积
- volume 代表书的页数

回归分析

续本达

复习提示

线性回归

多元线性回归


模型选择



热敏电阻

泊松回归

广义线性回归


hard back: 硬纸壳封面





## 绘制重量与页数的关系

```
plot(weight ~ volume, books)
```



复习提示

线性回归


多元线性回归

模型选择

热敏电阻

泊松回归

广义线性回归



- 变量  $x$  和  $y$  于图中呈**直线关系**。

- 欲求出与各点最**匹配**的直线，

$$y = a + bx$$


匹配：横向、纵向、垂线？

- 记观测值为  $(x_1, y_1), \dots, (x_N, y_N)$

最小二乘法估计  $a, b$

取**残差平方和**  $E^2(a, b) = \sum_{i=1}^N [y_i - (a + bx_i)]^2$  刻画点与线的差异，

以使  $E^2$  最小时的  $a, b$  为估计值  $\hat{a}, \hat{b} = \arg \min_{a, b} E^2(a, b)$



- 变量  $x$  和  $y$  于图中呈**直线关系**。
- 欲求出与各点最**匹配**的直线，

$$y = a + bx$$


匹配：横向、纵向、垂线？

- 记观测值为  $(x_1, y_1), \dots, (x_N, y_N)$

最小二乘法估计  $a, b$

取**残差平方和**  $E^2(a, b) = \sum_{i=1}^N [y_i - (a + bx_i)]^2$  刻画点与线的差异，

以使  $E^2$  最小时的  $a, b$  为估计值  $\hat{a}, \hat{b} = \arg \min_{a, b} E^2(a, b)$



- 变量  $x$  和  $y$  于图中呈**直线关系**。
- 欲求出与各点最**匹配**的直线，

$$y = a + bx$$

匹配：横向、纵向 ✓ **预测**、垂线？


- 记观测值为  $(x_1, y_1), \dots, (x_N, y_N)$

### 最小二乘法估计 $a, b$

取**残差平方和**  $E^2(a, b) = \sum_{i=1}^N [y_i - (a + bx_i)]^2$  刻画点与线的差异，

以使  $E^2$  最小时的  $a, b$  为估计值  $\hat{a}, \hat{b} = \arg \min_{a, b} E^2(a, b)$





- 变量  $x$  和  $y$  于图中呈**直线关系**。
- 欲求出与各点最**匹配**的直线，

$$y = a + bx$$

匹配：横向、纵向 ✓ **预测**、垂线？

- 记观测值为  $(x_1, y_1), \dots, (x_N, y_N)$

### 最小二乘法估计 $a, b$

取**残差平方和**  $E^2(a, b) = \sum_{i=1}^N [y_i - (a + bx_i)]^2$  刻画点与线的差异，

以使  $E^2$  最小时的  $a, b$  为估计值  $\hat{a}, \hat{b} = \arg \min_{a, b} E^2(a, b)$

## 最小二乘法的求解

$\hat{a}, \hat{b} = \arg \min_{a,b} E^2(a,b)$  有多种解法：配平方；求导  $\frac{\partial E^2}{\partial(a,b)} = 0$ 。

## 线性代数视角

把残差记为  $\epsilon_i = y_i - (a + bx_i)$ ，有  $y_i = 1a + x_ib + \epsilon_i$ ，写成  $N$  维列向量，

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} a + \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix} b + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{pmatrix}$$

## 最小二乘法的求解

$\hat{a}, \hat{b} = \arg \min_{a,b} E^2(a,b)$  有多种解法：配平方；求导  $\frac{\partial E^2}{\partial(a,b)} = 0$ 。

## 线性代数视角

把残差记为  $\epsilon_i = y_i - (a + bx_i)$ ，有  $y_i = 1a + x_ib + \epsilon_i$ ，写成  $N$  维列向量，

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} a + \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix} b + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{pmatrix}$$

$\hat{a}, \hat{b} = \arg \min_{a,b} E^2(a,b)$  有多种解法：配平方；求导  $\frac{\partial E^2}{\partial(a,b)} = 0$ 。

## 线性代数视角

把残差记为  $\epsilon_i = y_i - (a + bx_i)$ ，有  $y_i = 1a + x_ib + \epsilon_i$ ，写成  $N$  维列向量，

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} a + \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix} b + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{pmatrix}$$

$\hat{a}, \hat{b} = \arg \min_{a,b} E^2(a,b)$  有多种解法：配平方；求导  $\frac{\partial E^2}{\partial(a,b)} = 0$ 。

## 线性代数视角

把残差记为  $\epsilon_i = y_i - (a + bx_i)$ ，有  $y_i = 1a + x_ib + \epsilon_i$ ，写成  $N$  维列向量，

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} a + \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix} b + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_N \end{pmatrix}$$

$$\vec{Y} = (\vec{X}_1, \vec{X}_2) \begin{pmatrix} a \\ b \end{pmatrix} + \vec{E}$$


- 残差平方和  $E^2 = \sum \epsilon_i^2$  是  $\vec{E}$  欧几里得距离的平方  $\|\vec{E}\|^2$

$\vec{Y} = (\vec{X}_1, \vec{X}_2) \begin{pmatrix} a \\ b \end{pmatrix} + \vec{E}$ , 当  $a, b$  为何值能使  $\|\vec{E}\|^2$  最小?

- $N$  维线性空间中, 当  $a\vec{X}_1 + b\vec{X}_2$  是  $\vec{Y}$  向子空间的投影时,  $\|\vec{E}\|^2$  最小。

$\vec{E} = \vec{Y} - (a\vec{X}_1 + b\vec{X}_2)$  取极小

$\vec{X}_1$  与  $\vec{X}_2$  张成 2 维子空间



- 因此  $\vec{E}$  必与子空间垂直


$$\begin{cases} \vec{E} \cdot \vec{X}_1 = 0 \\ \vec{E} \cdot \vec{X}_2 = 0 \end{cases}$$

$\vec{Y} = (\vec{X}_1, \vec{X}_2) \begin{pmatrix} a \\ b \end{pmatrix} + \vec{E}$ , 当  $a, b$  为何值能使  $\|\vec{E}\|^2$  最小?

- $N$  维线性空间中, 当  $a\vec{X}_1 + b\vec{X}_2$  是  $\vec{Y}$  向子空间的投影时,  $\|\vec{E}\|^2$  最小。

$\vec{E} = \vec{Y} - (a\vec{X}_1 + b\vec{X}_2)$  取极小

$\vec{X}_1$  与  $\vec{X}_2$  张成 2 维子空间



- 因此  $\vec{E}$  必与子空间垂直


$$\begin{cases} \vec{E} \cdot \vec{X}_1 = 0 \\ \vec{E} \cdot \vec{X}_2 = 0 \end{cases}$$

$\vec{Y} = (\vec{X}_1, \vec{X}_2) \begin{pmatrix} a \\ b \end{pmatrix} + \vec{E}$ , 当  $a, b$  为何值能使  $\|\vec{E}\|^2$  最小?

- $N$  维线性空间中, 当  $a\vec{X}_1 + b\vec{X}_2$  是  $\vec{Y}$  向子空间的投影时,  $\|\vec{E}\|^2$  最小。

$\vec{E} = \vec{Y} - (a\vec{X}_1 + b\vec{X}_2)$  取极小

$\vec{X}_1$  与  $\vec{X}_2$  张成 2 维子空间



- 因此  $\vec{E}$  必与子空间垂直

$$\begin{cases} \vec{E} \cdot \vec{X}_1 = 0 \\ \vec{E} \cdot \vec{X}_2 = 0 \end{cases}$$




$\vec{Y} = (\vec{X}_1, \vec{X}_2) \begin{pmatrix} a \\ b \end{pmatrix} + \vec{E}$ , 当  $a, b$  为何值能使  $\|\vec{E}\|^2$  最小?

- $N$  维线性空间中, 当  $a\vec{X}_1 + b\vec{X}_2$  是  $\vec{Y}$  向子空间的投影时,  $\|\vec{E}\|^2$  最小。

$\vec{E} = \vec{Y} - (a\vec{X}_1 + b\vec{X}_2)$  取极小

$\vec{X}_1$  与  $\vec{X}_2$  张成 2 维子空间



- 因此  $\vec{E}$  必与子空间垂直


$$\begin{cases} \vec{E} \cdot \vec{X}_1 = 0 \\ \vec{E} \cdot \vec{X}_2 = 0 \end{cases}$$

$\vec{Y} = (\vec{X}_1, \vec{X}_2) \begin{pmatrix} a \\ b \end{pmatrix} + \vec{E}$ , 当  $a, b$  为何值能使  $\|\vec{E}\|^2$  最小?

- $N$  维线性空间中, 当  $a\vec{X}_1 + b\vec{X}_2$  是  $\vec{Y}$  向子空间的投影时,  $\|\vec{E}\|^2$  最小。

$\vec{E} = \vec{Y} - (a\vec{X}_1 + b\vec{X}_2)$  取极小

$\vec{X}_1$  与  $\vec{X}_2$  张成 2 维子空间



- 因此  $\vec{E}$  必与子空间垂直

$$\begin{cases} \vec{E} \cdot \vec{X}_1 = \sum_i [y_i - (a + bx_i)] \cdot 1 = \frac{\partial E^2}{\partial a} = 0 \\ \vec{E} \cdot \vec{X}_2 = \sum_i [y_i - (a + bx_i)] x_i = \frac{\partial E^2}{\partial b} = 0 \end{cases}$$

```
lm.books = lm(weight ~ volume, books)
summary(lm.books)
```

Call:

```
lm(formula = weight ~ volume, data = books)
```

Residuals:

|  | Min     | 1Q      | Median | 3Q     | Max    |
|--|---------|---------|--------|--------|--------|
|  | -189.97 | -109.86 | 38.08  | 109.73 | 145.57 |

Coefficients:

|             | Estimate  | Std. Error | t value | Pr(> t )     |
|-------------|-----------|------------|---------|--------------|
| (Intercept) | 107.67931 | 88.37758   | 1.218   | 0.245        |
| volume      | 0.70864   | 0.09746    | 7.271   | 6.26e-06 *** |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 123.9 on 13 degrees of freedom

Multiple R-squared: 0.8026, Adjusted R-squared: 0.7875

F-statistic: 52.87 on 1 and 13 DF, p-value: 6.262e-06

- $y = a + bx + \epsilon$ 
  - $\hat{a} = 108$  不显著
  - $\hat{b} = 0.71$  显著
- 回归方程为  

$$y = 108 + 0.71x + \epsilon$$
- 显著度
  - $\hat{a}$  和  $\hat{b}$  都服从  $t$ -分布

Coefficients:


|             | Estimate  | Std. Error | t value | Pr(> t )     |
|-------------|-----------|------------|---------|--------------|
| (Intercept) | 107.67931 | 88.37758   | 1.218   | 0.245        |
| volume      | 0.70864   | 0.09746    | 7.271   | 6.26e-06 *** |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

# 显著性检验的必要性


即使两个量毫无关联，仍可（流于形式地）做最小二乘法。



- 必须对回归结果进行假设检验，才能理解回归系数的含义。
- 回归所得的  $b$ ，与 0 有显著差异吗？

# 显著性检验的必要性



即使两个量毫无关联，仍可（流于形式地）做最小二乘法。



- 必须对回归结果进行**假设检验**，才能理解回归系数的含义。
- 回归所得的  $b$ ，与 0 有显著差异吗？

## 显著性检验的必要性

即使两个量毫无关联，仍可（流于形式地）做最小二乘法。



- 必须对回归结果进行**假设检验**，才能理解回归系数的含义。
- 回归所得的  $b$ ，与 0 有显著差异吗？


假设：残差服从正态分布

$$\epsilon_i = y_i - (a + bx_i) \sim N(0, \sigma^2)$$

经过最小二乘法获得的最佳  $a, b$  记为  $\hat{a}, \hat{b}$

记  $\hat{y}_i = \hat{a} + \hat{b}x_i$ ，称为回归的**预测值**：

$$\underbrace{\sum_{i=1}^N (y_i - \bar{y})^2}_{S_T \text{ 偏差平方和}} = \underbrace{\sum_{i=1}^N (y_i - \hat{y}_i)^2}_{S_E \text{ 误差平方和}} + \underbrace{\sum_{i=1}^N (\bar{y} - \hat{y}_i)^2}_{S_A \text{ 效应平方和}}$$





$$R^2 = \frac{S_A}{S_T}$$

越接近于 1，越说明  $S_A$  主导  $S_T$ ，相关性越强。

## 假设检验问题

- 任意两个变量的一组观察值  $\{(x_i, y_i)\}$  都可用最小二乘法形式上求得  $y$  对  $x$  的回归方程
- 若  $y$  与  $x$  没有线性相关关系，回归方程无意义
- 考察  $y$  与  $x$  间是否确有线性相关关系，是回归效果的 **检验问题**。

$$R^2 = \frac{S_A}{S_T}$$

越接近于 1，越说明  $S_A$  主导  $S_T$ ，相关性越强。

## 假设检验问题

- 任意两个变量的一组观察值  $\{(x_i, y_i)\}$  都可用最小二乘法形式上求得  $y$  对  $x$  的回归方程
- 若  $y$  与  $x$  没有线性相关关系，回归方程无意义
- 考察  $y$  与  $x$  间是否确有线性相关关系，是回归效果的 **检验问题**。

$$R^2 = \frac{S_A}{S_T}$$

越接近于 1 ，越说明  $S_A$  主导  $S_T$ ，相关性越强。

## 假设检验问题

- 任意两个变量的一组观察值  $\{(x_i, y_i)\}$  都可用最小二乘法形式上求得  $y$  对  $x$  的回归方程
- 若  $y$  与  $x$  没有线性相关关系，回归方程无意义
- 考察  $y$  与  $x$  间是否确有线性相关关系，是回归效果的 **检验问题**。

$$H_0 : b = 0, H_1 : b \neq 0$$

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{S_T, \nu_T = n-1} = \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{S_E, \nu_E = n-p} + \underbrace{\sum_{i=1}^n (\bar{y} - \hat{y}_i)^2}_{S_M, \nu_M = p-1} - \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)(\bar{y} - \hat{y}_i)}_0$$

$S_M$  模型变差。进行线性回归的预测值与  $Y$  样本均值的差异  
 $p$  回归参数个数，一元线性回归取 2


$$\frac{S_M/1}{S_E/(n-2)} = F \sim F(1, n-2)$$

$$R^2 = \frac{S_M}{S_T}$$

Multiple R-squared: 0.8026, Adjusted R-squared: 0.7875

F-statistic: 52.87 on 1 and 13 DF, p-value: 6.262e-06

```
library(ggplot2)
p = ggplot(books, aes(x=volume, y=weight)) + geom_point()
print(p + geom_smooth(method="lm"))
```





ggplot2 中内嵌了 lm 自动给出回归结果。


## 拟合优度的制图判定

```
plot(lm.books)
```


**Standardized residual** 经过期望平移和标准差伸缩后的量，服从标准正态分布。

**Theoretical Quantiles** 标准正态分布。






标准化的残差图



Cook scaling-location 图，检验残差大小的一致性

```
books$predicted = predict(lm.books)  
plot(weight~predicted, books)  
abline(0, 1)
```





- 细致描述变量依赖，扩展公式表达。使用 `model.matrix` 厘清内部机理

```
model.matrix(weight ~ volume, books)
```

```
(Intercept) volume
1           1      885
2           1     1016
3           1     1125
4           1      239
5           1      701
6           1      641
7           1     1228
8           1      412
9           1      953
10          1      929
11          1     1492
12          1      419
13          1     1010
14          1      595
15          1     1034
attr(,"assign")
[1] 0 1
```

- 线性回归可以推广到多个变量

## 还可以包含离散变量


- 每个离散变量，实际上对应多个自由参数，个数等于离散变量的取值数

```
books$cover = as.factor(books$cover)
books[c("weight", "volume", "cover")]
```

|    | weight | volume | cover |
|----|--------|--------|-------|
| 1  | 800    | 885    | hb    |
| 2  | 950    | 1016   | hb    |
| 3  | 1050   | 1125   | hb    |
| 4  | 350    | 239    | hb    |
| 5  | 750    | 701    | hb    |
| 6  | 600    | 641    | hb    |
| 7  | 1075   | 1228   | hb    |
| 8  | 250    | 412    | pb    |
| 9  | 700    | 953    | pb    |
| 10 | 650    | 929    | pb    |
| 11 | 975    | 1492   | pb    |
| 12 | 350    | 419    | pb    |
| 13 | 950    | 1010   | pb    |
| 14 | 425    | 595    | pb    |
| 15 | 725    | 1034   | pb    |

- 书的包装有什么影响？画图探索

```
print(p + aes(color=cover))
```



```
lm2.books <- lm(weight ~ volume + cover, books)
summary(lm2.books)
```

Call:

```
lm(formula = weight ~ volume + cover, data = books)
```

Residuals:

|  | Min     | 1Q     | Median | 3Q    | Max    |
|--|---------|--------|--------|-------|--------|
|  | -110.10 | -32.32 | -16.10 | 28.93 | 210.95 |

Coefficients:

|             | Estimate   | Std. Error | t value | Pr(> t ) |     |
|-------------|------------|------------|---------|----------|-----|
| (Intercept) | 197.96284  | 59.19274   | 3.344   | 0.005841 | **  |
| volume      | 0.71795    | 0.06153    | 11.669  | 6.6e-08  | *** |
| coverpb     | -184.04727 | 40.49420   | -4.545  | 0.000672 | *** |

---


Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 78.2 on 12 degrees of freedom

Multiple R-squared: 0.9275, Adjusted R-squared: 0.9154

F-statistic: 76.73 on 2 and 12 DF, p-value: 1.455e-07


```
print(p + aes(color=cover) + geom_smooth(method="lm"))
```



- 令  $\vec{X}_0 = \vec{1}, \vec{X}_1 = \vec{x}, \vec{X}_2 = \vec{x}^2$ :

$$\vec{E} = \vec{Y} - (b_0\vec{X}_0 + b_1\vec{X}_1 + b_2\vec{X}_2)$$

$\vec{X}_0, \vec{X}_1$  与  $\vec{X}_2$  张成子空间




## 推广

- 替换投影子空间的基
- 添加新的基，构成更高维的子空间，实现多元线性回归。

- 令  $\vec{X}_0 = \vec{1}$ ,  $\vec{X}_1 = \vec{x}$ ,  $\vec{X}_2 = \vec{x}^2$ :

$$\vec{E} = \vec{Y} - (b_0\vec{X}_0 + b_1\vec{X}_1 + b_2\vec{X}_2)$$

$\vec{X}_0, \vec{X}_1$  与  $\vec{X}_2$  张成子空间



## 推广

- 替换投影子空间的基
- 添加新的基，构成更高维的子空间，实现多元线性回归。

- 一组观测值  $\vec{Y}$  若与多组自变量  $\vec{X}_0, \vec{X}_1, \vec{X}_2, \dots, \vec{X}_p$  有关,

$$\vec{Y} = (\vec{X}_0, \vec{X}_1, \vec{X}_2, \dots, \vec{X}_p) \begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_p \end{pmatrix} + \vec{E}$$

- 可以使用最小二乘法得到  $\hat{b}_0, \hat{b}_1, \hat{b}_2, \dots, \hat{b}_p$ .



```
model.matrix(weight ~ volume + cover, books)
```

```
(Intercept) volume coverpb
1           1      885      0
2           1     1016      0
3           1     1125      0
4           1      239      0
5           1      701      0
6           1      641      0
7           1     1228      0
8           1      412      1
9           1      953      1
10          1      929      1
11          1     1492      1
12          1      419      1
13          1     1010      1
14          1      595      1
15          1     1034      1
attr(,"assign")
[1] 0 1 2
attr(,"contrasts")
attr(,"contrasts")$cover
[1] "contr.treatment"
```

```
model.matrix(weight ~ volume + cover - 1, books)
```

|    | volume | coverhb | coverpb |
|----|--------|---------|---------|
| 1  | 885    | 1       | 0       |
| 2  | 1016   | 1       | 0       |
| 3  | 1125   | 1       | 0       |
| 4  | 239    | 1       | 0       |
| 5  | 701    | 1       | 0       |
| 6  | 641    | 1       | 0       |
| 7  | 1228   | 1       | 0       |
| 8  | 412    | 0       | 1       |
| 9  | 953    | 0       | 1       |
| 10 | 929    | 0       | 1       |
| 11 | 1492   | 0       | 1       |
| 12 | 419    | 0       | 1       |
| 13 | 1010   | 0       | 1       |
| 14 | 595    | 0       | 1       |
| 15 | 1034   | 0       | 1       |

```
attr(,"assign")  
[1] 1 2 2  
attr(,"contrasts")  
attr(,"contrasts")$cover  
[1] "contr.treatment"
```

```
lm3.books = lm(weight ~ volume + cover - 1, books)
summary(lm3.books)
```

Call:

```
lm(formula = weight ~ volume + cover - 1, data = books)
```

Residuals:

|  | Min     | 1Q     | Median | 3Q    | Max    |
|--|---------|--------|--------|-------|--------|
|  | -110.10 | -32.32 | -16.10 | 28.93 | 210.95 |

Coefficients:

|         | Estimate  | Std. Error | t value | Pr(> t ) |     |
|---------|-----------|------------|---------|----------|-----|
| volume  | 0.71795   | 0.06153    | 11.669  | 6.6e-08  | *** |
| coverhb | 197.96284 | 59.19274   | 3.344   | 0.00584  | **  |
| coverpb | 13.91557  | 59.45408   | 0.234   | 0.81889  |     |


---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 78.2 on 12 degrees of freedom

Multiple R-squared: 0.9914, Adjusted R-squared: 0.9892

F-statistic: 459.5 on 3 and 12 DF, p-value: 1.207e-12




## Occam's razor and Von Neumann's elephant

如果关于同一个问题有许多种理论，每一种都能作出同样准确的预言，那么应该挑选其中使用假定最少的。

### elephant

With four parameters I can fit an elephant. With five I can make him wiggle his trunk.



- 赤池信息判据：应当用多少个变量描述模型？变量越多，拟合越精确；变量越少，模型越简明。

$$AIC = 2n - 2 \log \mathcal{L}$$

其中  $n$  是变量个数， $\mathcal{L}$  是拟合似然函数 (likelihood)

## R 中的 AIC

```
AIC(lm.books) # weight ~ volume  
AIC(lm2.books) # weight ~ volume + cover  
AIC(lm3.books) # weight ~ volume + cover - 1
```

```
[1] 191.016  
[1] 177.9986  
[1] 177.9986
```

- lm2 与 lm3 等价，两者的 model.matrix 可用通过线性变换等价互换

- 回归结果说明 paper back 不应该有截距，只有 hard back 才有截距。
  - 使用公式已经无法表达这个需求

Coefficients:

|         | Estimate  | Std. Error | t value | Pr(> t ) |     |
|---------|-----------|------------|---------|----------|-----|
| volume  | 0.71795   | 0.06153    | 11.669  | 6.6e-08  | *** |
| coverhb | 197.96284 | 59.19274   | 3.344   | 0.00584  | **  |
| coverpb | 13.91557  | 59.45408   | 0.234   | 0.81889  |     |

使用 `model.matrix` 改进模型• 直接修改 `model.matrix`

```
model4 <- model.matrix(weight ~ volume + cover - 1, books)
model4 <- model4[,1:2]
```

885 1

1016 1

1125 1

239 1

701 1

641 1

1228 1

412 0

953 0

929 0

1492 0

419 0

1010 0

595 0

1024 0



```
lm4.books <- lm(weight ~ model4, books)
```

```
AIC(lm4.books)
```

```
summary(lm4.books)
```

```
[1] 176.0669
```

```
Call:
```

```
lm(formula = weight ~ model4 - 1, data = books)
```

```
Residuals:
```

| Min      | 1Q      | Median | 3Q     | Max     |
|----------|---------|--------|--------|---------|
| -115.208 | -32.277 | -9.768 | 30.447 | 211.991 |

```
Coefficients:
```

|               | Estimate  | Std. Error | t value | Pr(> t ) |     |
|---------------|-----------|------------|---------|----------|-----|
| model4volume  | 0.73070   | 0.02755    | 26.522  | 1.05e-12 | *** |
| model4coverhb | 187.33601 | 36.57152   | 5.122   | 0.000196 | *** |

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 75.3 on 13 degrees of freedom
```

```
Multiple R-squared:  0.9913, Adjusted R-squared:  0.99
```

```
F-statistic: 743.2 on 2 and 13 DF,  p-value: 3.954e-14
```

- 分析：有否必要把 area 加入回归？

```
lm5.books = lm(weight ~ volume + area - 1, books)
summary(lm5.books) # AIC = 175.9741
```

Call:

```
lm(formula = weight ~ volume + area - 1, data = books)
```

Residuals:

| Min     | 1Q     | Median | 3Q    | Max    |
|---------|--------|--------|-------|--------|
| -112.53 | -28.73 | -10.52 | 24.62 | 213.80 |

Coefficients:

|        | Estimate | Std. Error | t value | Pr(> t ) |     |
|--------|----------|------------|---------|----------|-----|
| volume | 0.72891  | 0.02767    | 26.344  | 1.15e-12 | *** |
| area   | 0.48087  | 0.09344    | 5.146   | 0.000188 | *** |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 75.07 on 13 degrees of freedom

Multiple R-squared: 0.9914, Adjusted R-squared: 0.9901

F-statistic: 747.9 on 2 and 13 DF, p-value: 3.799e-14

- 电子体温计使用方便



工作原理：金属氧化物热敏电阻

- 负温度系数型：随着温度升高，电阻值变小

- 电子体温计使用方便



工作原理：金属氧化物热敏电阻

- 负温度系数型：随着温度升高，电阻值变小

# 电子体温计

**別了！水银溫度計！**

**我国明确將禁止生产  
含汞体温计、血压计产品**

已经取得医疗器械注册证的  
含汞体温计和含汞血压计产品，  
原注册证在证书有效期内继续有效；  
注册证有效期届满可以申请延续注册，  
但限定其注册证有效期  
不得超过2025年12月31日。

来源：中国市场监管报

来源：市场监管报

- 电子体温计使用方便



工作原理：金属氧化物热敏电阻

- 负温度系数型：随着温度升高，电阻值变小

# 电子体温计



**別了！水银溫度計！**

**我国明确將禁止生产  
含汞体温计、血压计产品**

已经取得医疗器械注册证的  
含汞体温计和含汞血压计产品，  
原注册证在证书有效期内继续有效；  
注册证有效期届满可以申请延续注册，  
但限定其注册证有效期  
不得超过2025年12月31日。

来源：中国市场监管报


来源：市场监管报



- 温度  $t$  与电阻  $R$  有对应关系

- 变成直线  $t \rightarrow \frac{1}{t + 273.15 \text{ K}}$  简称为  $y$ ,  $R \rightarrow \log \frac{R}{\text{k}\Omega}$  简称为  $x$ 。

Calibration and self-validation of thermistors for high-precision temperature measurements, Measurement Vol 76, 2015



- 温度  $t$  与电阻  $R$  有对应关系
- 变成直线  $t \rightarrow \frac{1}{t + 273.15 \text{ K}}$  简称为  $y$ ,  $R \rightarrow \log \frac{R}{\text{k}\Omega}$  简称为  $x$ 。

Calibration and self-validation of thermistors for high-precision temperature measurements, Measurement Vol 76, 2015

- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程



- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程

- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程

- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程

- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程

- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程

- 在许多实际问题中，两个变量之间并不一定是线性关系，而是某种曲线关系，应该用曲线来拟合.
- 可以进行适当的变量代换，把它线性化，这样就把一个非线性回归问题化为线性回归问题而得以解决.

## 步骤

- ① 根据样本数据，在直角坐标系中画出散点图
- ② 根据散点图，推测出  $Y$  与  $x$  之间的函数关系
- ③ 选择适当的坐标变换，使之变成线性关系
- ④ 用线性回归方法求出线性回归方程
- ⑤ 返回到原来的函数关系，得到要求的回归方程

```
lm.therm = lm(1/(温度 + 273.15) ~ log(电阻), d)
summary(lm.therm)
```

Call:

```
lm(formula = 1/(温度 + 273.15) ~ log(电阻), data = d)
```

Residuals:

|  | Min        | 1Q         | Median     | 3Q        | Max       |
|--|------------|------------|------------|-----------|-----------|
|  | -1.662e-04 | -3.961e-05 | -5.900e-07 | 3.852e-05 | 1.693e-04 |

Coefficients:

|             | Estimate  | Std. Error | t value | Pr(> t )   |
|-------------|-----------|------------|---------|------------|
| (Intercept) | 3.349e-03 | 2.571e-06  | 1302.50 | <2e-16 *** |
| log(电阻)     | 2.305e-04 | 3.387e-06  | 68.06   | <2e-16 *** |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.349e-05 on 438 degrees of freedom

Multiple R-squared: 0.9136, Adjusted R-squared: 0.9134

F-statistic: 4632 on 1 and 438 DF, p-value: < 2.2e-16

复习提示

线性回归

多元线性回归

模型选择


热敏电阻

泊松回归

广义线性回归

$$\begin{cases} \hat{a} = 3.353(3) \times 10^{-3} \\ \hat{b} = 2.364(35) \times 10^{-4} \end{cases}$$

$$y = \hat{a} + \hat{b}x$$





检验假设  $H_0 : b = 0, H_1 : b \neq 0$

- $\hat{b}$  满足  $\hat{b} \sim N\left(b, \frac{\sigma^2}{L_{xx}}\right)$  其中  $L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}$
- 因此如果原假设成立,  $\hat{b}\sqrt{L_{xx}}/\sigma \sim N(0, 1), Q_e/\sigma^2 \sim \chi^2(n-2)$

$$\frac{\hat{b}\sqrt{L_{xx}}/\sigma}{\sqrt{\frac{Q_e/\sigma^2}{n-2}}} = \frac{\hat{b}\sqrt{L_{xx}}}{\sqrt{\frac{Q_e}{n-2}}} = t \sim t(n-2)$$

- 选取拒绝域  $|t| \geq t_{\alpha/2}(n-2)$  进行  $t$  检验。

## 区间估计

类似  $\hat{b}$ ,  $\hat{a}$  以及  $\hat{Y} = \hat{a} + \hat{b}x$  都可经线性变换构造  $t$  分布统计量, 进行区间估计。

检验假设  $H_0 : b = 0, H_1 : b \neq 0$

- $\hat{b}$  满足  $\hat{b} \sim N\left(b, \frac{\sigma^2}{L_{xx}}\right)$  其中  $L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}$
- 因此如果原假设成立,  $\hat{b}\sqrt{L_{xx}}/\sigma \sim N(0, 1)$ ,  $Q_e/\sigma^2 \sim \chi^2(n-2)$

$$\frac{\hat{b}\sqrt{L_{xx}}/\sigma}{\sqrt{\frac{Q_e/\sigma^2}{n-2}}} = \frac{\hat{b}\sqrt{L_{xx}}}{\sqrt{\frac{Q_e}{n-2}}} = t \sim t(n-2)$$

- 选取拒绝域  $|t| \geq t_{\alpha/2}(n-2)$  进行  $t$  检验。

## 区间估计

类似  $\hat{b}$ ,  $\hat{a}$  以及  $\hat{Y} = \hat{a} + \hat{b}x$  都可经线性变换构造  $t$  分布统计量, 进行区间估计。

检验假设  $H_0 : b = 0, H_1 : b \neq 0$

- $\hat{b}$  满足  $\hat{b} \sim N\left(b, \frac{\sigma^2}{L_{xx}}\right)$  其中  $L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}$
- 因此如果原假设成立,  $\hat{b}\sqrt{L_{xx}}/\sigma \sim N(0, 1)$ ,  $Q_e/\sigma^2 \sim \chi^2(n-2)$


$$\frac{\hat{b}\sqrt{L_{xx}}/\sigma}{\sqrt{\frac{Q_e/\sigma^2}{n-2}}} = \frac{\hat{b}\sqrt{L_{xx}}}{\sqrt{\frac{Q_e}{n-2}}} = t \sim t(n-2)$$

- 选取拒绝域  $|t| \geq t_{\alpha/2}(n-2)$  进行  $t$  检验。

## 区间估计

类似  $\hat{b}$ ,  $\hat{a}$  以及  $\hat{Y} = \hat{a} + \hat{b}x$  都可经线性变换构造  $t$  分布统计量, 进行区间估计。

## 热敏电阻的更精确模型




$$\frac{K}{T} = a + b \log \frac{R}{k\Omega}$$
$$y = a + bx$$

- 加入更高阶项，可以描述更复杂的关系。

$$\frac{K}{T} = b_0 + b_1 \log \frac{R}{k\Omega} + b_2 \left( \log \frac{R}{k\Omega} \right)^2 + b_3 \left( \log \frac{R}{k\Omega} \right)^3 \dots$$

- 如何确定高阶项的系数？

## 热敏电阻的更精确模型



$$\frac{K}{T} = a + b \log \frac{R}{k\Omega}$$
$$y = a + bx$$

- 加入更高阶项，可以描述更复杂的关系。

$$\frac{K}{T} = b_0 + b_1 \log \frac{R}{k\Omega} + b_2 \left( \log \frac{R}{k\Omega} \right)^2 + b_3 \left( \log \frac{R}{k\Omega} \right)^3 \dots$$

- 如何确定高阶项的系数？

$$\frac{K}{T} = 3.326 \times 10^{-3} + 3.641 \times 10^{-3} \log \frac{R}{k\Omega} - 3.624 \times 10^{-4} \left( \log \frac{R}{k\Omega} \right)^3$$

| 系数    | 值                              | 显著? |
|-------|--------------------------------|-----|
| $b_0$ | $3.326(2) \times 10^{-3}$      | 是   |
| $b_1$ | $3.641(51) \times 10^{-3}$     | 是   |
| $b_2$ | $-1.112(50730) \times 10^{-6}$ | 否   |
| $b_3$ | $-3.624(507) \times 10^{-4}$   | 是   |


- 红色线对应 Starnhart-Hart 公式。
- 参数越多，拟合得越好，但模型越复杂。

Steinhart and Hart *Calibration curves for thermistors*, 1968

## 热敏电阻的多元线性回归

$$\frac{K}{T} = 3.326 \times 10^{-3} + 3.641 \times 10^{-3} \log \frac{R}{k\Omega} - 3.624 \times 10^{-4} \left( \log \frac{R}{k\Omega} \right)^3$$

| 系数    | 值                              | 显著? |
|-------|--------------------------------|-----|
| $b_0$ | $3.326(2) \times 10^{-3}$      | 是   |
| $b_1$ | $3.641(51) \times 10^{-3}$     | 是   |
| $b_2$ | $-1.112(50730) \times 10^{-6}$ | 否   |
| $b_3$ | $-3.624(507) \times 10^{-4}$   | 是   |




- 红色线对应 Steinhart-Hart 公式。
- 参数越多，拟合得越好，但模型越复杂。

Steinhart and Hart *Calibration curves for thermistors*, 1968

## 例子：辐射热计量

- 每次有放射性衰变，二氧化碲  $\text{TeO}_2$  晶体都会“发烧”升温，



- 通过给晶体“量体温”，确定中微子是否它自身的反粒子，以及中微子质量。



中子嬗变掺杂锗热敏电阻的线性回归


“体温计”为“中子嬗变掺杂（NTD）”的锗热敏电阻。由线性回归标定：

$$\sqrt{\frac{T_0}{T}} = a + b \log \left( \frac{R}{R_0} \right)$$

精度达到  $\mu\text{K}$ ，是一般热敏电阻的 1000 倍。



- 每次有放射性衰变，二氧化碲  $\text{TeO}_2$  晶体都会“发烧”升温，



- 通过给晶体“量体温”，确定中微子是否它自身的反粒子，以及中微子质量。



### 中子嬗变掺杂锗热敏电阻的线性回归

“体温计”为“中子嬗变掺杂（NTD）”的锗热敏电阻。由线性回归标定：

$$\sqrt{\frac{T_0}{T}} = a + b \log \left( \frac{R}{R_0} \right)$$

精度达到  $\mu\text{K}$ ，是一般热敏电阻的 1000 倍。

残差不服从正态分布时，以线性模型解决问题 → 广义线性回归。

- 泊松回归：观测量是计数
- 伽马回归：观测量是正实数
- 逻辑回归：观测量是  $[0, 1]$  区间内的实数
- 二项回归：观测量是  $0, 1, \dots, N$  的整数


## 例：盖革计数器的放射性计量

2023 年 8 月 24 日至 9 月 11 日，日本福岛第一核电站核污染水排海 7788 吨。

早在 2012 年德国海洋研究团队模拟了污水的扩散过程。

- 环境放射性，由探头计数测量。
- 计数个数反映了辐射强弱 → 样例视频。

# 例：盖革计数器的放射性计量



2023 年 8 月 24 日至 9 月 11 日，日本福岛第一核电站核污染水排海 7788 吨。

早在 2012 年德国海洋研究团队模拟了污水的扩散过程。

- 环境放射性，由探头计数测量。
- 计数个数反映了辐射强弱 → 样例视频。



## 计数问题：规律探寻

10s 内积累的信号数  $N$ ，依赖于样品辐射强度  $I$  和探头距离  $r$ 。


$$N = \frac{I}{r^s}, \quad s \approx 2$$

$r$  和  $N$  已测得， $I$  和  $s$  待求。

- 尝试转化为线性回归

$$\log N = \log I - s \log r$$

$N = 0$  的数据点如何处理？把  $\log N$  换成  $\log(N + 1)$ 。



## 计数问题：规律探寻

10s 内积累的信号数  $N$ ，依赖于样品辐射强度  $I$  和探头距离  $r$ 。


$$N = \frac{I}{r^s}, \quad s \approx 2$$

$r$  和  $N$  已测得， $I$  和  $s$  待求。

- 尝试转化为线性回归

$$\log N = \log I - s \log r$$

$N = 0$  的数据点如何处理？把  $\log N$  换成  $\log(N + 1)$ 。



## 计数问题：规律探寻

10s 内积累的信号数  $N$ ，依赖于样品辐射强度  $I$  和探头距离  $r$ 。


$$N = \frac{I}{r^s}, \quad s \approx 2$$

$r$  和  $N$  已测得， $I$  和  $s$  待求。


- 尝试转化为线性回归

$$\log N = \log I - s \log r$$

$N = 0$  的数据点如何处理？把  $\log N$  换成  $\log(N + 1)$ 。



## 计数问题：线性回归



在不同距离下计数的方差不固定  
 计数量是离散的


不符合线性回归的正态分布假设

$$Y_i \sim N(a + bx_i, \sigma^2)$$


方差不固定  $\xrightarrow{\text{加权线性回归}}$   $Y_i \sim N(a + bx_i, \sigma_i^2)$



## 计数问题：线性回归





在不同距离下计数的方差不固定  
计数量是离散的



不符合线性回归的正态分布假设  
 $Y_i \sim N(a + bx_i, \sigma^2)$

方差不固定  $\xrightarrow{\text{加权线性回归}}$   $Y_i \sim N(a + bx_i, \sigma_i^2)$

## 计数问题：线性回归



在不同距离下计数的方差不固定  
计数量是离散的

不符合线性回归的正态分布假设  
 $Y_i \sim N(a + bx_i, \sigma^2)$

方差不固定  $\xrightarrow{\text{加权线性回归}}$   $Y_i \sim N(a + bx_i, \sigma_i^2)$

# 计数问题：把残差假设替换为泊松分布

计数问题中，残差的正态假设失效，但数据呈现依赖关系。

- 把正态分布  $N(\cdot, \sigma^2)$  换成贴近计数问题的泊松分布  $\pi(\cdot)$

$$\begin{aligned} Y_i &\sim N[E(Y_i), \sigma^2], & E(Y_i) &= a + bx_i \\ \text{替换为 } Y_i &\sim \pi[E(Y_i)], & \log E(Y_i) &= a + bx_i \end{aligned}$$

$E(Y_i)$  代表随机变量  $Y_i$  的期望（均值）。

定义：泊松回归

观测量  $y_i$  相对于预测量  $E(Y_i) = e^{a+bx_i}$  为泊松分布的回归模型，称**泊松回归**。

# 计数问题：把残差假设替换为泊松分布

计数问题中，残差的正态假设失效，但数据呈现依赖关系。

- 把正态分布  $N(\cdot, \sigma^2)$  换成贴近计数问题的泊松分布  $\pi(\cdot)$

$$\begin{aligned} Y_i &\sim N[E(Y_i), \sigma^2], & E(Y_i) &= a + bx_i \\ \text{替换为 } Y_i &\sim \pi[E(Y_i)], & \log E(Y_i) &= a + bx_i \end{aligned}$$

$E(Y_i)$  代表随机变量  $Y_i$  的期望（均值）。

定义：泊松回归

观测量  $y_i$  相对于预测量  $E(Y_i) = e^{a+bx_i}$  为泊松分布的回归模型，称**泊松回归**。

## 计数问题：把残差假设替换为泊松分布

计数问题中，残差的正态假设失效，但数据呈现依赖关系。

- 把正态分布  $N(\cdot, \sigma^2)$  换成贴近计数问题的泊松分布  $\pi(\cdot)$

$$Y_i \sim N[E(Y_i), \sigma^2], \quad E(Y_i) = a + bx_i$$

替换为  $Y_i \sim \pi[E(Y_i)], \quad \log E(Y_i) = a + bx_i$

$E(Y_i)$  代表随机变量  $Y_i$  的期望（均值）。

定义：泊松回归

观测量  $y_i$  相对于预测量  $E(Y_i) = e^{a+bx_i}$  为泊松分布的回归模型，称**泊松回归**。

一组相互独立的数据  $(x_i, y_i)$ ，其中  $y_i$  为计数。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i$$

- 当  $x_i$  确定时,  $a, b$  决定了  $Y_i$  的泊松分布参数,

$$\begin{aligned} P(Y_i = y_i | a, b) &= \frac{[E(Y_i)]^{y_i}}{y_i!} e^{-E(Y_i)} \\ &= \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)} \end{aligned}$$

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

- $a, b$  取不同的值时, 观测得到的  $(x_i, y_i)$  的概率不同。

一组相互独立的数据  $(x_i, y_i)$ ，其中  $y_i$  为计数。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i$$

- 当  $x_i$  确定时， $a, b$  决定了  $Y_i$  的泊松分布参数，

$$\begin{aligned} P(Y_i = y_i | a, b) &= \frac{[E(Y_i)]^{y_i}}{y_i!} e^{-E(Y_i)} \\ &= \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)} \end{aligned}$$

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

- $a, b$  取不同的值时，观测得到的  $(x_i, y_i)$  的概率不同。

一组相互独立的数据  $(x_i, y_i)$ ，其中  $y_i$  为计数。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i$$

- 当  $x_i$  确定时， $a, b$  决定了  $Y_i$  的泊松分布参数，

$$\begin{aligned} P(Y_i = y_i | a, b) &= \frac{[E(Y_i)]^{y_i}}{y_i!} e^{-E(Y_i)} \\ &= \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)} \end{aligned}$$

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

- $a, b$  取不同的值时，观测得到的  $(x_i, y_i)$  的概率不同。



一组相互独立的数据  $(x_i, y_i)$ ，其中  $y_i$  为计数。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i$$

- 当  $x_i$  确定时， $a, b$  决定了  $Y_i$  的泊松分布参数，

$$\begin{aligned} P(Y_i = y_i | a, b) &= \frac{[E(Y_i)]^{y_i}}{y_i!} e^{-E(Y_i)} \\ &= \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)} \end{aligned}$$

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

- $a, b$  取不同的值时，观测得到的  $(x_i, y_i)$  的概率不同。

一组相互独立的数据  $(x_i, y_i)$ ，其中  $y_i$  为计数。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i$$

- 当  $x_i$  确定时， $a, b$  决定了  $Y_i$  的泊松分布参数，

$$\begin{aligned} P(Y_i = y_i | a, b) &= \frac{[E(Y_i)]^{y_i}}{y_i!} e^{-E(Y_i)} \\ &= \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)} \end{aligned}$$

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

- $a, b$  取不同的值时，观测得到的  $(x_i, y_i)$  的概率不同。

## 定义复习：似然函数

观测发生的概率关于模型参数的函数称为**似然函数**。

- 已经测量  $x_i, y_i$  时，

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

是  $a, b$  的函数，是模型和观测值的似然函数  $\mathcal{L}(a, b)$

## 最大似然估计

即找到对应使  $(x_i, y_i)$  概率最大的一组  $\hat{a}, \hat{b}$  为解。取  $\log$  方便计算

$$\hat{a}, \hat{b} = \arg \max_{a, b} \log \mathcal{L}(a, b) = \arg \max_{a, b} \sum_i y_i (a + bx_i) - e^{(a + bx_i)}$$

定义复习：似然函数

观测发生的概率关于模型参数的函数称为**似然函数**。

- 已经测量  $x_i, y_i$  时，

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

是  $a, b$  的函数，是模型和观测值的似然函数  $\mathcal{L}(a, b)$

最大似然估计

即找到对应使  $(x_i, y_i)$  概率最大的一组  $\hat{a}, \hat{b}$  为解。取  $\log$  方便计算

$$\hat{a}, \hat{b} = \arg \max_{a, b} \log \mathcal{L}(a, b) = \arg \max_{a, b} \sum_i y_i (a + bx_i) - e^{(a + bx_i)}$$

定义复习：似然函数

观测发生的概率关于模型参数的函数称为**似然函数**。

- 已经测量  $x_i, y_i$  时，

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

是  $a, b$  的函数，是模型和观测值的似然函数  $\mathcal{L}(a, b)$

## 最大似然估计

即找到对应使  $(x_i, y_i)$  概率最大的一组  $\hat{a}, \hat{b}$  为解。取  $\log$  方便计算

$$\hat{a}, \hat{b} = \arg \max_{a, b} \log \mathcal{L}(a, b) = \arg \max_{a, b} \sum_i y_i (a + bx_i) - e^{(a + bx_i)}$$

定义复习：似然函数

观测发生的概率关于模型参数的函数称为**似然函数**。

- 已经测量  $x_i, y_i$  时，

$$P(\vec{Y} = \vec{y} | a, b) = \prod_i \frac{[\exp(a + bx_i)]^{y_i}}{y_i!} e^{-\exp(a + bx_i)}$$

是  $a, b$  的函数，是模型和观测值的似然函数  $\mathcal{L}(a, b)$

## 最大似然估计

即找到对应使  $(x_i, y_i)$  概率最大的一组  $\hat{a}, \hat{b}$  为解。取  $\log$  方便计算

$$\hat{a}, \hat{b} = \arg \max_{a, b} \log \mathcal{L}(a, b) = \arg \max_{a, b} \sum_i y_i (a + bx_i) - e^{(a + bx_i)}$$

$$\log \mathcal{L}[E(\vec{Y})] = \sum_i y_i \log[E(Y_i)] - E(Y_i), \quad \frac{\partial \log \mathcal{L}[E(\vec{Y})]}{\partial [E(Y_i)]} = \frac{y_i}{E(Y_i)} - 1$$

若  $E(\vec{Y})$  不受  $e^{(a+bx_i)}$  约束,  $\mathcal{L}[E(\vec{Y})]$  在  $E(\vec{Y}) = \vec{y}$  时取最大。

定义预测值  $E(\vec{Y})$  到观测值  $\vec{y}$  的“距离”  $\mathcal{D}$

- 令其越小代表两者符合得越好, 取 0 时代表两者“相等”。

$$\begin{aligned} \mathcal{D}[E(\vec{Y}), \vec{y}] &= \left[ \log \underbrace{\mathcal{L}[E(\vec{Y}) = \vec{y}]}_{\text{似然函数的最大取值}} - \log \mathcal{L}[E(\vec{Y})] \right] \\ &= \left[ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right] \end{aligned}$$

$$\log \mathcal{L}[E(\vec{Y})] = \sum_i y_i \log[E(Y_i)] - E(Y_i), \quad \frac{\partial \log \mathcal{L}[E(\vec{Y})]}{\partial [E(Y_i)]} = \frac{y_i}{E(Y_i)} - 1$$

若  $E(\vec{Y})$  不受  $e^{(a+bx_i)}$  约束,  $\mathcal{L}[E(\vec{Y})]$  在  $E(\vec{Y}) = \vec{y}$  时取最大。

定义预测值  $E(\vec{Y})$  到观测值  $\vec{y}$  的“距离”  $\mathcal{D}$

- 令其越小代表两者符合得越好, 取 0 时代表两者“相等”。

$$\begin{aligned} \mathcal{D}[E(\vec{Y}), \vec{y}] &= \left[ \log \underbrace{\mathcal{L}[E(\vec{Y}) = \vec{y}]}_{\text{似然函数的最大取值}} - \log \mathcal{L}[E(\vec{Y})] \right] \\ &= \left[ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right] \end{aligned}$$



$$\log \mathcal{L}[E(\vec{Y})] = \sum_i y_i \log[E(Y_i)] - E(Y_i), \quad \frac{\partial \log \mathcal{L}[E(\vec{Y})]}{\partial [E(Y_i)]} = \frac{y_i}{E(Y_i)} - 1$$

若  $E(\vec{Y})$  不受  $e^{(a+bx_i)}$  约束,  $\mathcal{L}[E(\vec{Y})]$  在  $E(\vec{Y}) = \vec{y}$  时取最大。

定义预测值  $E(\vec{Y})$  到观测值  $\vec{y}$  的“距离”  $\mathcal{D}$

- 令其越小代表两者符合得越好, 取 0 时代表两者“相等”。

$$\begin{aligned} \mathcal{D}[E(\vec{Y}), \vec{y}] &= 2 \left[ \log \underbrace{\mathcal{L}[E(\vec{Y}) = \vec{y}]}_{\text{似然函数的最大取值}} - \log \mathcal{L}[E(\vec{Y})] \right] \\ &= 2 \left[ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right] \end{aligned}$$

通常再乘上系数 2, 动机来自正态分布 (下页)。

$$\log \mathcal{L}[E(\vec{Y})] = \sum_i y_i \log[E(Y_i)] - E(Y_i), \quad \frac{\partial \log \mathcal{L}[E(\vec{Y})]}{\partial [E(Y_i)]} = \frac{y_i}{E(Y_i)} - 1$$

若  $E(\vec{Y})$  不受  $e^{(a+bx_i)}$  约束,  $\mathcal{L}[E(\vec{Y})]$  在  $E(\vec{Y}) = \vec{y}$  时取最大。

定义预测值  $E(\vec{Y})$  到观测值  $\vec{y}$  的“距离”  $\mathcal{D}$

- 令其越小代表两者符合得越好, 取 0 时代表两者“相等”。

$$\begin{aligned} \mathcal{D}[E(\vec{Y}), \vec{y}] &= 2 \left[ \log \underbrace{\mathcal{L}[E(\vec{Y}) = \vec{y}]}_{\text{似然函数的最大取值}} - \log \mathcal{L}[E(\vec{Y})] \right] \\ &= 2 \left[ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right] \end{aligned}$$

通常再乘上系数 2, 动机来自正态分布 (下页)。

$$\log \mathcal{L}[E(\vec{Y})] = \sum_i y_i \log[E(Y_i)] - E(Y_i), \quad \frac{\partial \log \mathcal{L}[E(\vec{Y})]}{\partial [E(Y_i)]} = \frac{y_i}{E(Y_i)} - 1$$

若  $E(\vec{Y})$  不受  $e^{(a+bx_i)}$  约束,  $\mathcal{L}[E(\vec{Y})]$  在  $E(\vec{Y}) = \vec{y}$  时取最大。

定义预测值  $E(\vec{Y})$  到观测值  $\vec{y}$  的“距离”  $\mathcal{D}$

- 令其越小代表两者符合得越好, 取 0 时代表两者“相等”。

$$\begin{aligned} \mathcal{D}[E(\vec{Y}), \vec{y}] &= 2 \left[ \log \underbrace{\mathcal{L}[E(\vec{Y}) = \vec{y}]}_{\text{似然函数的最大取值}} - \log \mathcal{L}[E(\vec{Y})] \right] \\ &= 2 \left[ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right] \end{aligned}$$

通常再乘上系数 2, 动机来自正态分布 (下页)。

## 考虑正态分布的对数似然距离

$$\mathcal{D}[\mathbf{E}(\vec{Y}), \vec{y}] = 2 \underbrace{\{\log \mathcal{L}[\mathbf{E}(\vec{Y}) = \vec{y}]\}}_{(\vec{y} - \vec{y})^2 / (2\sigma^2) = 0} - \log \mathcal{L}[\mathbf{E}(\vec{Y})] = \sum_i [\mathbf{E}(\vec{Y}_i) - y_i]^2 / \sigma^2$$

正是线性回归使用的残差平方和。

## 启示

泊松分布的“对数似然距离”，可看作是“残差平方和”的推广。

$$\hat{a}, \hat{b} = \arg \max_{a,b} \log \mathcal{L}_i(a, b) = \arg \min_{a,b} \mathcal{D}(e^{a+bx_i}, y_i)$$

考虑正态分布的对数似然距离

$$\mathcal{D}[\mathbf{E}(\vec{Y}), \vec{y}] = 2 \underbrace{\{\log \mathcal{L}[\mathbf{E}(\vec{Y}) = \vec{y}] - \log \mathcal{L}[\mathbf{E}(\vec{Y})]\}}_{(\vec{y} - \vec{y})^2 / (2\sigma^2) = 0} = \sum_i [\mathbf{E}(\vec{Y}_i) - y_i]^2 / \sigma^2$$

正是线性回归使用的**残差平方和**。

启示

泊松分布的“对数似然距离”，可看作是“残差平方和”的推广。

$$\hat{a}, \hat{b} = \arg \max_{a,b} \log \mathcal{L}_i(a, b) = \arg \min_{a,b} \mathcal{D}(e^{a+bx_i}, y_i)$$

考虑正态分布的对数似然距离

$$\mathcal{D}[\mathbf{E}(\vec{Y}), \vec{y}] = 2 \underbrace{\{\log \mathcal{L}[\mathbf{E}(\vec{Y}) = \vec{y}]\}}_{(\vec{y} - \vec{y})^2 / (2\sigma^2) = 0} - \log \mathcal{L}[\mathbf{E}(\vec{Y})] = \sum_i [\mathbf{E}(\vec{Y}_i) - y_i]^2 / \sigma^2$$

正是线性回归使用的残差平方和。

启示


泊松分布的“对数似然距离”，可看作是“残差平方和”的推广。

$$\hat{a}, \hat{b} = \arg \max_{a, b} \log \mathcal{L}_i(a, b) = \arg \min_{a, b} \mathcal{D}(e^{a+bx_i}, y_i)$$

## 对数似然距离的直观理解

$$\sum_i [(a + bx_i) - y_i]^2$$


残差平方和：



图：线性回归

$$\mathcal{D}(e^{a+bx_i}, y_i)$$

对数似然距离，非线性：




图：泊松回归

使用最小二乘法，可解析求解线性回归模型，能否推广到泊松回归？

## 对数似然距离的直观理解

$$\sum_i [(a + bx_i) - y_i]^2$$


残差平方和：



图：线性回归

$$\mathcal{D}(e^{a+bx_i}, y_i)$$

对数似然距离，非线性：



图：泊松回归


使用**最小二乘法**，可解析求解线性回归模型，能否推广到**泊松回归**？



## 对数似然距离的直观理解

$$\sum_i [(a + bx_i) - y_i]^2$$


残差平方和：



图：线性回归

$$\mathcal{D}(e^{a+bx_i}, y_i)$$

对数似然距离，非线性：



图：泊松回归

使用**最小二乘法**，可解析求解线性回归模型，能否推广到**泊松回归**？

## 求解数似然函数距离的极小值

以最小对数似然距离求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i] \\ \Rightarrow 0 &= \frac{\partial \log \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]}{\partial b} \\ &= \sum_i \left[ -\frac{y_i}{\mathbf{E}(Y_i)} + 1 \right] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b}\end{aligned}$$

$$\Rightarrow 0 = \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i)] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{\mathbf{E}(Y_i)} \frac{\partial}{\partial b} [y_i - \mathbf{E}(Y_i|a, b)]^2$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/\mathbf{E}(Y_i)$  被看作常数时，线性回归与泊松回归等价。

构造最小二乘法求  $\hat{b}$ :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \underbrace{\sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2}_{\text{加权的残差平方和}} \\ \Rightarrow 0 &= \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2 \right\}\end{aligned}$$

## 求解数似然函数距离的极小值

构造最小二乘法求  $\hat{b}$ :以最小对数似然距离求  $\hat{b}$ :

$$\hat{a}, \hat{b} = \arg \min_{a, b} \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]$$

$$\Rightarrow 0 = \frac{\partial \log \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]}{\partial b}$$

$$= \sum_i \left[ -\frac{y_i}{\mathbf{E}(Y_i)} + 1 \right] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b}$$

$$\Rightarrow 0 = \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i)] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{\mathbf{E}(Y_i)} \frac{\partial}{\partial b} [y_i - \mathbf{E}(Y_i|a, b)]^2$$

$$\hat{a}, \hat{b} = \arg \min_{a, b} \underbrace{\sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2}_{\text{加权的残差平方和}}$$

$$\Rightarrow 0 = \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2 \right\}$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/\mathbf{E}(Y_i)$  被看作常数时，线性回归与泊松回归等价。

## 求解数似然函数距离的极小值

以最小对数似然距离求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i] \\ \Rightarrow 0 &= \frac{\partial \log \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]}{\partial b} \\ &= \sum_i \left[ -\frac{y_i}{\mathbf{E}(Y_i)} + 1 \right] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b}\end{aligned}$$

$$\Rightarrow 0 = \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i)] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{\mathbf{E}(Y_i)} \frac{\partial}{\partial b} [y_i - \mathbf{E}(Y_i|a, b)]^2$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/\mathbf{E}(Y_i)$  被看作常数时，线性回归与泊松回归等价。

构造最小二乘法求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \underbrace{\sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2}_{\text{加权的残差平方和}} \\ \Rightarrow 0 &= \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2 \right\}\end{aligned}$$

## 求解数似然函数距离的极小值

构造最小二乘法求  $\hat{b}$ :以最小对数似然距离求  $\hat{b}$ :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a, b} \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i] \\ \Rightarrow 0 &= \frac{\partial \log \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]}{\partial b} \\ &= \sum_i \left[ -\frac{y_i}{\mathbf{E}(Y_i)} + 1 \right] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b}\end{aligned}$$

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a, b} \underbrace{\sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2}_{\text{加权的残差平方和}} \\ \Rightarrow 0 &= \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2 \right\}\end{aligned}$$

$$\Rightarrow 0 = \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i)] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{\mathbf{E}(Y_i)} \frac{\partial}{\partial b} [y_i - \mathbf{E}(Y_i|a, b)]^2$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/\mathbf{E}(Y_i)$  被看作常数时，线性回归与泊松回归等价。

## 求解数似然函数距离的极小值

以最小对数似然距离求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a, b} \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i] \\ \Rightarrow 0 &= \frac{\partial \log \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]}{\partial b} \\ &= \sum_i \left[ -\frac{y_i}{\mathbf{E}(Y_i)} + 1 \right] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b}\end{aligned}$$

$$\Rightarrow 0 = \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i)] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{\mathbf{E}(Y_i)} \frac{\partial}{\partial b} [y_i - \mathbf{E}(Y_i|a, b)]^2$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/\mathbf{E}(Y_i)$  被看作常数时，线性回归与泊松回归等价。

构造最小二乘法求  $\hat{b}$ :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a, b} \underbrace{\sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2}_{\text{加权的残差平方和}} \\ \Rightarrow 0 &= \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2 \right\}\end{aligned}$$

## 求解数似然函数距离的极小值

以最小对数似然距离求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i] \\ \Rightarrow 0 &= \frac{\partial \log \mathcal{D}[\mathbf{E}(Y_i|a, b), y_i]}{\partial b} \\ &= \sum_i \left[ -\frac{y_i}{\mathbf{E}(Y_i)} + 1 \right] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b}\end{aligned}$$

$$\Rightarrow 0 = \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i)] \frac{\partial \mathbf{E}(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{\mathbf{E}(Y_i)} \frac{\partial}{\partial b} [y_i - \mathbf{E}(Y_i|a, b)]^2$$

构造最小二乘法求  $\hat{b}$ :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \underbrace{\sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2}_{\text{加权的残差平方和}} \\ \Rightarrow 0 &= \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{\mathbf{E}(Y_i)} [y_i - \mathbf{E}(Y_i|a, b)]^2 \right\}\end{aligned}$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/\mathbf{E}(Y_i)$  被看作常数时，线性回归与泊松回归等价。

## 求解数似然函数距离的极小值

以最小对数似然距离求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \mathcal{D}[E(Y_i|a, b), y_i] \\ \Rightarrow 0 &= \frac{\partial \log \mathcal{D}[E(Y_i|a, b), y_i]}{\partial b} \\ &= \sum_i \left[ -\frac{y_i}{E(Y_i)} + 1 \right] \frac{\partial E(Y_i|a, b)}{\partial b}\end{aligned}$$

$$\Rightarrow 0 = \sum_i \frac{1}{E(Y_i)} [y_i - E(Y_i)] \frac{\partial E(Y_i|a, b)}{\partial b} = -\frac{1}{2} \sum_i \frac{1}{E(Y_i)} \frac{\partial}{\partial b} [y_i - E(Y_i|a, b)]^2$$


构造最小二乘法求  $\hat{b}$  :

$$\begin{aligned}\hat{a}, \hat{b} &= \arg \min_{a,b} \underbrace{\sum_i \frac{1}{E(Y_i)} [y_i - E(Y_i|a, b)]^2}_{\text{加权的残差平方和}} \\ \Rightarrow 0 &= \frac{\partial}{\partial b} \left\{ \sum_i \frac{1}{E(Y_i)} [y_i - E(Y_i|a, b)]^2 \right\}\end{aligned}$$

- 两者解相同，对数似然距离与残差平方和等价。
- 当权重  $1/E(Y_i)$  被看作常数时，线性回归与泊松回归等价。



$$a_0, b_0 \rightarrow E(Y_i) = a_0 + b_0 x_i \xrightarrow{\text{求解线性回归}} a_1, b_1 \rightarrow E(Y_i) = a_1 + b_1 x_i \cdots$$



要寻找曲面上距离已知点  $Y$  最近的点，

- ① 在曲线上猜一个位置  $B_0, i \leftarrow 0$ ;
- ② 从  $Y$  向  $B_i$  处的切空间投影得  $B'$ ;
- ③ 令  $B_{i+1} \leftarrow B', i \leftarrow i + 1$ ;
- ④ 若  $B_{i+1} = B_i$  则得解，  
否则回到第 2 步。

$$a_0, b_0 \rightarrow E(Y_i) = a_0 + b_0 x_i \xrightarrow{\text{求解线性回归}} a_1, b_1 \rightarrow E(Y_i) = a_1 + b_1 x_i \cdots$$

要寻找曲面上距离已知点  $Y$  最近的点，

- ① 在曲线上猜一个位置  $B_0, i \leftarrow 0$ ;
- ② 从  $Y$  向  $B_i$  处的切空间投影得  $B'$ ;
- ③ 令  $B_{i+1} \leftarrow B', i \leftarrow i + 1$ ;
- ④ 若  $B_{i+1} = B_i$  则得解，  
否则回到第 2 步。

- 信号数  $N$ ，依赖于样品辐射强度  $I$  和探头距离  $r$ 。

$$N = \frac{I}{r^s}$$


$$\log N = \log I - s \log r$$

|      | $\log I$          | $s$                |
|------|-------------------|--------------------|
| 线性回归 | $1.726 \pm 0.067$ | $-1.092 \pm 0.067$ |
| 泊松回归 | $1.727 \pm 0.057$ | $-2.08 \pm 0.13$   |
| 参考值  | 1.792             | -2                 |

- 信号数  $N$ ，依赖于样品辐射强度  $I$  和探头距离  $r$ 。


$$N = \frac{I}{r^s}$$

$$\log N = \log I - s \log r$$



|      | $\log I$          | $s$                |
|------|-------------------|--------------------|
| 线性回归 | $1.726 \pm 0.067$ | $-1.092 \pm 0.067$ |
| 泊松回归 | $1.727 \pm 0.057$ | $-2.08 \pm 0.13$   |
| 参考值  | 1.792             | -2                 |


# 泊松回归在实验物理（中微子望远镜）的应用



上万个计数器协同工作，测量中微子能量，定出中微子位置。

- 运用泊松回归方法实现测量精度的大幅提升。

# 泊松回归在实验物理（中微子望远镜）的应用



上万个计数器协同工作，测量中微子能量，定出中微子位置。

- 运用泊松回归方法实现测量精度的大幅提升。

《原子核仪器与物理学研究方法》期刊 NIMA Volume 1057, December 2023, 168692

$$N_i \sim \pi[E(N_i)]$$

在中微子探测问题中，考虑中微子在介质中的反应位置  $\vec{r}$ 。需要获得  $Y_i$  与  $\vec{r}$  的关系，当反应点与  $\vec{r}_i$  处的 PMT 距离较远时，可用平方反比近似。

$$E(N_i) = \frac{I}{(|\vec{r}_i - \vec{r}|)^s}$$

如果再考虑介质对闪烁光的吸收，吸收长度为  $L_0$ 。

$$E(N_i) = \frac{I}{(|\vec{r}_i - \vec{r}|)^s} e^{-\frac{|\vec{r}_i - \vec{r}|}{L_0}}$$

取  $\log$  成为线性关系，

$$\log E(N_i) = \log I - s \log(|\vec{r}_i - \vec{r}|) - \frac{1}{L_0} |\vec{r}_i - \vec{r}|$$

在探测器刻度中， $\vec{r}$  已知。通过泊松回归获得  $\log I, s, \frac{1}{L_0}$ 。

$$N_i \sim \pi[E(N_i)]$$

在中微子探测问题中，考虑中微子在介质中的反应位置  $\vec{r}$ 。需要获得  $Y_i$  与  $\vec{r}$  的关系，当反应点与  $\vec{r}_i$  处的 PMT 距离较远时，可用平方反比近似。

$$E(N_i) = \frac{I}{(|\vec{r}_i - \vec{r}|)^s}$$

如果再考虑介质对闪烁光的吸收，吸收长度为  $L_0$ 。

$$E(N_i) = \frac{I}{|\vec{r}_i - \vec{r}|^s} e^{-\frac{|\vec{r}_i - \vec{r}|}{L_0}}$$

取  $\log$  成为线性关系，

$$\log E(N_i) = \log I - s \log(|\vec{r}_i - \vec{r}|) - \frac{1}{L_0} |\vec{r}_i - \vec{r}|$$

在探测器刻度中， $\vec{r}$  已知。通过泊松回归获得  $\log I, s, \frac{1}{L_0}$ 。



$$N_i \sim \pi[E(N_i)]$$

在中微子探测问题中，考虑中微子在介质中的反应位置  $\vec{r}$ 。需要获得  $Y_i$  与  $\vec{r}$  的关系，当反应点与  $\vec{r}_i$  处的 PMT 距离较远时，可用平方反比近似。

$$E(N_i) = \frac{I}{(|\vec{r}_i - \vec{r}|)^s}$$

如果再考虑介质对闪烁光的吸收，吸收长度为  $L_0$ 。

$$E(N_i) = \frac{I}{|\vec{r}_i - \vec{r}|^s} e^{-\frac{|\vec{r}_i - \vec{r}|}{L_0}}$$

取  $\log$  成为线性关系，

$$\log E(N_i) = \log I - s \log(|\vec{r}_i - \vec{r}|) - \frac{1}{L_0} |\vec{r}_i - \vec{r}|$$

在探测器刻度中， $\vec{r}$  已知。通过泊松回归获得  $\log I, s, \frac{1}{L_0}$ 。

重建中，中微子事例的位置  $\vec{r}$  与能量  $E$  是待求量。

$$\log E(N_i) = \log I - s \log(|\vec{r}_i - \vec{r}|) - \frac{1}{L_0} |\vec{r}_i - \vec{r}|$$

- ① 对于假定的位置  $\vec{r}$ ，基于刻度标定的  $s, L_0$ ，回归  $I$  得到事例能量；
- ②  $\hat{I}$  替换  $I$  计算回归的似然函数  $\mathcal{L}(\vec{r})$ ；
- ③ 利用最大似然法求得  $\hat{\vec{r}} = \arg \max_{\vec{r}} \mathcal{L}(\vec{r})$ 。

思考（开放问题，取得解者 +5%）

有可能把  $\hat{\vec{r}}$  的求解过程化为线性回归问题吗？

一般性地求解  $E[N_i(\vec{r})]$ 。

- 再加上时间维度的信息， $E[N_i(\vec{r}, t)]$ 。
- 可考虑使用回归方法取得函数形式，例如对时间取小区间。
- 难点：加入了时间之后，如何线性化表示  $N_i(\vec{r}, t)$  函数关系？

- ① 把线性回归中的正态假设替换为泊松假设，得到泊松回归。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i.$$

将简洁有效的线性回归方法范围推广到计数问题。

- ② 泊松对数似然距离，是正态残差平方和的推广：

$$\mathcal{D}[E(\vec{Y}), \vec{y}] = 2 \left\{ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right\}.$$

- ③ 变权迭代最小二乘法把线性回归的框架应用于泊松回归：

$$a_0, b_0 \rightarrow E(Y_i) = a_0 + b_0 x_i \xrightarrow{\text{求解线性回归}} a_1, b_1 \rightarrow E(Y_i) = a_1 + b_1 x_i \cdots$$

启示：用线性方法可以高效解决看似非线性的问题。

- ① 把线性回归中的正态假设替换为**泊松假设**，得到**泊松回归**。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i.$$

将简洁有效的线性回归方法范围推广到**计数问题**。

- ② 泊松对数似然距离，是正态残差平方和的推广：

$$\mathcal{D}[E(\vec{Y}), \vec{y}] = 2 \left\{ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right\}.$$

- ③ 变权迭代最小二乘法把线性回归的框架应用于泊松回归：

$$a_0, b_0 \rightarrow E(Y_i) = a_0 + b_0 x_i \xrightarrow{\text{求解线性回归}} a_1, b_1 \rightarrow E(Y_i) = a_1 + b_1 x_i \cdots$$

启示：用**线性方法**可以高效解决看似**非线性**的问题。

- ① 把线性回归中的正态假设替换为泊松假设，得到泊松回归。

$$Y_i \sim \pi[E(Y_i)], \log E(Y_i) = a + bx_i.$$

将简洁有效的线性回归方法范围推广到计数问题。

- ② 泊松对数似然距离，是正态残差平方和的推广：

$$\mathcal{D}[E(\vec{Y}), \vec{y}] = 2 \left\{ \sum_i y_i \log \frac{y_i}{E(Y_i)} - [y_i - E(Y_i)] \right\}.$$

- ③ 变权迭代最小二乘法把线性回归的框架应用于泊松回归：

$$a_0, b_0 \rightarrow E(Y_i) = a_0 + b_0 x_i \xrightarrow{\text{求解线性回归}} a_1, b_1 \rightarrow E(Y_i) = a_1 + b_1 x_i \cdots$$

启示：用线性方法可以高效解决看似非线性的问题。

## 指数分布族

一族的分布，它们的概率密度函数或分布律记为  $f(x|\vec{\theta})$ ，如果有

$$f(x|\vec{\theta}) = \exp \left[ \sum_{i=1}^s \eta_i(\vec{\theta}) T_i(x) - B(\vec{\theta}) \right] h(x)$$

的形式，则称为  $s$  维指数分布族。

如果把  $\eta_i(\vec{\theta})$  当作自变量反解  $\theta$ ，那么形式有进一步的化简。

## 指数分布族标准形式

$$f(x|\vec{\eta}) = \exp \left[ \sum_{i=1}^s \eta_i T_i(x) - A(\vec{\eta}) \right] h(x)$$

其中  $\eta_i = \eta_i(\vec{\theta})$ ,  $A[\vec{\eta}(\vec{\theta})] = B(\vec{\theta})$ 。

## 指数离散分布族 Exponential Dispersion Family

在指数分布族上再配一项  $\phi > 0$ 。

$$f(x|\vec{\eta}) = \exp \left[ \sum_{i=1}^s \eta_i T_i(x) - A(\vec{\eta}) \right] h(x)$$

变为

$$f(x|\phi, \vec{\eta}) = \exp \left\{ \sum_{i=1}^s \frac{1}{\phi} [\eta_i T_i(x) - A(\vec{\eta})] \right\} h(\phi, x)$$

当  $\phi$  取 1 时, Exponential Dispersion Family 就是 Exponential Family。

## 期望与方差

- 期望:  $E(X) = A'(\eta)$  不变, 记为  $\mu$
- 方差:  $\text{Var}(X) = A''(\eta) \rightarrow \text{Var}(X) = \phi A''(\eta)$ 
  - 所以  $\phi$  称为 **离散度参数** dispersion parameter。



- 期望:  $E(X) = \mu = A'(\eta)$
- 方差:  $\text{Var}(X) = \phi A''(\eta)$  说明  $A(\eta)'' > 0$
- 说明  $\mu(\eta) = A'(\eta)$  是单调函数,  $\eta$  与  $\mu$  之间有双射。

$$A'^{-1}(\mu) = \eta$$

## 方差函数

把  $A''(\eta)$  换为  $A''(A'^{-1}(\mu))$  定义为  $V(\mu)$ , 称 **方差函数**。那么

$$\text{Var}(X) = \phi V(\mu)$$

## 常见的指数离散分布族成员

| 名称      | $V(\mu)$                | $\eta$                      | $\phi$        | $d(x, \mu)$ |
|---------|-------------------------|-----------------------------|---------------|-------------|
| 正态      | 1                       | $\mu$                       | $\sigma^2$    |             |
| 二项      | $\mu(1 - \mu)$          | $\log \frac{\mu}{1-\mu}$    | $\frac{1}{N}$ |             |
| 泊松      | $\mu$                   | $\log \mu$                  | 1             |             |
| 伽马      | $\mu^2$                 | $-\frac{1}{\mu}$            | $\phi$        |             |
| 负二项     | $\mu + \frac{\mu^2}{k}$ | $\log \frac{\mu}{\mu+k}$    | 1             |             |
| 逆高斯     | $\mu^2$                 | $-\frac{1}{2\mu^2}$         | $\phi$        |             |
| Tweedie | $\mu^\xi$               | $\frac{\mu^{1-\xi}}{1-\xi}$ | $\phi$        |             |

对数似然距离记为  $d(x, \mu)$ ，近似地

$$\frac{d(x, \mu)}{\phi} \sim \chi^2(1)$$

- F-检验 与 t-检验都适用。

泊松回归是广义线性回归的一个特例。

- 常见的广义线性回归有
  - 负二项回归：观测量是非负整数，比泊松回归多一个参数
  - 伽马回归：观测量是正实数
    - 或者使用逆高斯分布。
  - 逻辑回归：观测量是  $[0, 1]$  区间内的实数
  - 二项回归：观测是  $0, 1, \dots, N$  的整数
    - 关注成功次数占总数的比例。
  - Tweedie 回归：
- 它们都可以通过变权迭代最小二乘法有效解出。

- 尝试对 r10500.h5 进行泊松回归
- 辅助文件 geo.csv , pmtdata.csv

```
library(rhdf5)
library(dplyr)
PEs <- h5read("lm-examples/r10500.h5", "PETruth")
PEs |> group_by(EventID, ChannelID) |> summarise(nPE=n()) -> nPE
PMT <- read.table("lm-examples/pmtdata.csv", col.names=c("ChannelID", "type", "QE"))
nPE |> inner_join(PMT) -> d
lm0.d <- glm(nPE ~ type - 1, d, family = poisson())
summary(lm0.d)
```

Call:

```
glm(formula = nPE ~ type - 1, family = poisson(), data = d)
```

Coefficients:

|               | Estimate  | Std. Error | z value | Pr(> z ) |     |
|---------------|-----------|------------|---------|----------|-----|
| typeHamamatsu | 3.3682078 | 0.0005870  | 5738.4  | <2e-16   | *** |
| typeHighQENNV | 3.3916647 | 0.0003988  | 8504.3  | <2e-16   | *** |
| typeHZC       | 0.3696733 | 0.0018707  | 197.6   | <2e-16   | *** |
| typeNNVT      | 3.2986176 | 0.0009531  | 3461.0  | <2e-16   | *** |
| ---           |           |            |         |          |     |

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

```
nPE |> right_join(PMT) -> d1  
head(d1[is.na(d1$nPE),])
```

|        |     |          |
|--------|-----|----------|
| 309056 | HZC | 0.255856 |
| 309157 | HZC | 0.241972 |
| 312822 | HZC | 0.236523 |
| 312823 | HZC | 0.254319 |
| 312841 | HZC | 0.241801 |
| 312842 | HZC | 0.227959 |

是没有计数的 PMT，已经损坏，不考虑使用 inner\_join 合理。

## 模型的选择

- ① 关系代数让回归分析变得极其直观，让我们专注于问题的本质
- ② 模型的选择极其重要，应当使用客观标准
  - AIC 是最简单直接的客观标准
  - 找到“最佳模型”的过程充满曲折，是实验“研究”的主体过程
- ③ 广义线性回归，把误差分布从高斯替换为其它指数族分布
  - 把连接函数从恒等替换为非线性函数
  - 几乎可以解决所有日常工作中的非线性问题，惊喜！